Reconstrucción y regularización en imágenes tomográficas

Trabajo Práctico — Métodos Computacionales

Ariel Alzogaray Flores Josefina Deserti Gotta

Universidad Torcuato Di Tella

Segundo semestre 2026

El problema

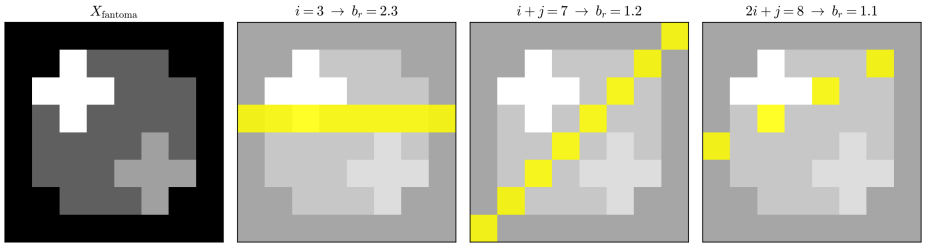
- Un rayo con intensidad I_0 atraviesa el objeto y llega con intensidad I.
- Cada detector mide la **atenuación acumulada** a lo largo de un rayo.
- Discretizamos la sección en $n \times n$ píxeles y la apilamos en $x \in \mathbb{R}^{n^2}$:

$$b = Ax, \qquad b_r = \sum_j a_{rj}\, x_j.$$

- **Problema inverso:** conocemos A (geometría) y b (mediciones); buscamos x (la imagen).

Preguntas: ¿la solución es única? ¿qué pasa con el ruido? ¿cómo la calculamos?

Imagen, rayos y matriz de proyección (Ej. 1–3)



- El píxel (i, j) ocupa la posición $k = i\,n + j$ del vector x.
- Modelo binario: un rayo discreto selecciona los píxeles con $\alpha i + \beta j = s$.
- A: cada **fila** es un rayo, cada **columna** un píxel. Es **rala**: cada rayo toca pocos píxeles.

¿Se puede reconstruir de forma única? (Ej. 4)

Teorema de rango y nulidad

$$\text{rango}(A) + \dim \text{Nul}(A) = 64$$

- Única $\iff$ $\text{rango}(A) = 64$ $\iff$ $\text{Nul}(A) = \{0\}$.
- Si $Av = 0$ con $v \neq 0$:

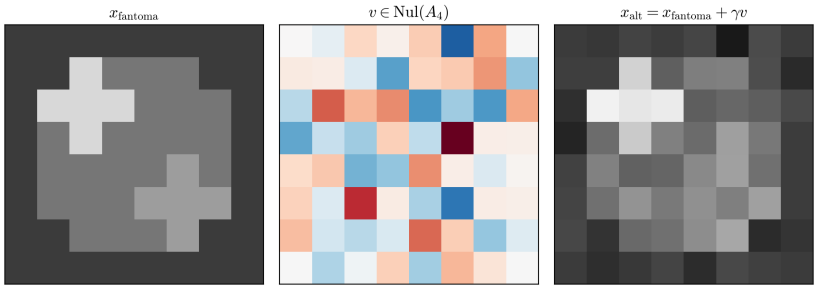
$$A(x + \gamma v) = Ax$$

dos imágenes distintas, mismas mediciones.

	tamaño	rango	$\dim \text{Nul}$
A_2	16×64	15	49
A_4	46×64	39	25
A_7	119×64	64	0

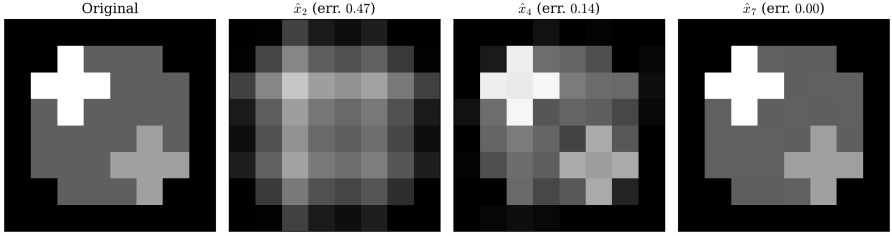
- Solo A_7 determina la imagen.
- Filas $>$ rango: hay **mediciones redundantes**.

Patrón “ciego” en A_4 (Ej. 4)



- v = vector singular asociado a $\sigma_{\text{mín}} \approx 0$ (SVD).
- $\|A_4 v\| \approx 0 \rightarrow x_{\text{fantoma}}$ y x_{alt} producen las mismas mediciones.
- v es un patrón de atenuación “invisible”

Reconstrucción sin ruido (Ej. 5)



	rango	$\|r_k\|$	error rel.
A_2	15	$\sim 10^{-15}$	0.47
A_4	39	$\sim 10^{-14}$	0.14
A_7	64	$\sim 10^{-14}$	$\sim 10^{-15}$

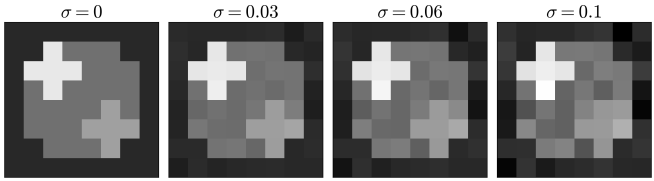
- El residuo es ≈ 0 en los tres casos.
- Pero solo A_7 recupera la imagen: `lstsq` da la solución de **norma mínima**, sin componente en $\mathrm{Nul}(A_k)$.
- Residuo nulo $\not\Rightarrow$ imagen correcta.

Mediciones con ruido (Ej. 6)

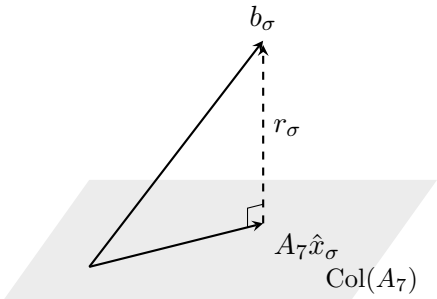
$$b_\sigma = b_7 + \sigma \cdot \text{escala} \cdot z, \qquad \hat{x}_\sigma = \arg\min_x \|A_7 x - b_\sigma\|^2$$

σ	$\|\eta\|$	$\|r\|$	error	mín
0	0	0	0	0
0.01	0.12	0.08	0.02	−0,02
0.03	0.37	0.25	0.06	−0,05
0.06	0.73	0.50	0.12	−0,10
0.10	1.22	0.84	0.20	−0,17

- El error crece proporcionalmente a σ.
- $r \neq 0$: en general $b_\sigma \notin \text{Col}(A_7)$, no hay solución exacta.
- Aparecen valores negativos: el ruido se propaga a $\hat{x}_\sigma$ sin ninguna restricción de signo.



Mínimos cuadrados como proyección ortogonal (Ej. 7)



- Ecuaciones normales:

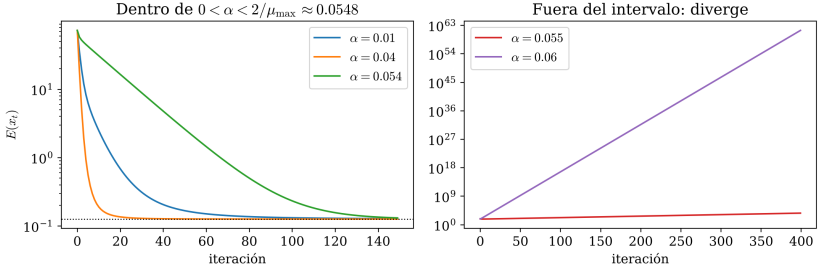
$$A_7^T A_7 \hat{x} = A_7^T b_\sigma \iff A_7^T r_\sigma = 0$$

- Numéricamente: $\|A_7^T r_\sigma\| \approx 4 \cdot 10^{-14}$.
- $r_\sigma \in \mathrm{Nul}(A_7^T) = \mathrm{Col}(A_7)^\perp$, entonces $A_7\hat{x}_\sigma$ es la proyección ortogonal de b_σ.

- La proyección *ortogonal* es la mejor aproximación en $\mathbb{R}^m$.

Gradiente descendiente (Ej. 8)

$$E(x) = \tfrac{1}{2}\|A_7 x - b_\sigma\|^2, \qquad \nabla E(x) = A_7^T(A_7 x - b_\sigma), \qquad H = A_7^T A_7 \text{ (simétrica)}$$



- $x_{t+1} = x_t - \alpha \nabla E(x_t)$, con $x_0 = 0$ y $\sigma = 0{,}06$.
- $\mu_{\text{máx}}(H) \approx 36{,}46$: converge si $0 < \alpha < 2/\mu_{\text{máx}} \approx 0{,}0548$; si no, diverge.

Método de Newton y comparación (Ej. 8)

- E es cuadrática $\Rightarrow$ su Taylor de orden 2 es **exacto** y H es constante:

$$x_1 = x_0 - H^{-1}\nabla E(x_0) = (A_7^T A_7)^{-1} A_7^T b_\sigma$$

  que es justo la solución de las ecuaciones normales: **una sola iteración**.

Método	iteraciones	$E(\hat{x})$	parámetros
`lstsq`	—	0.12604	ninguno
Newton	1	0.12604	x_0; requiere resolver con H
Gradiente ($\alpha = 0{,}054$)	167	0.12752	α, tolerancia, máx. iter.

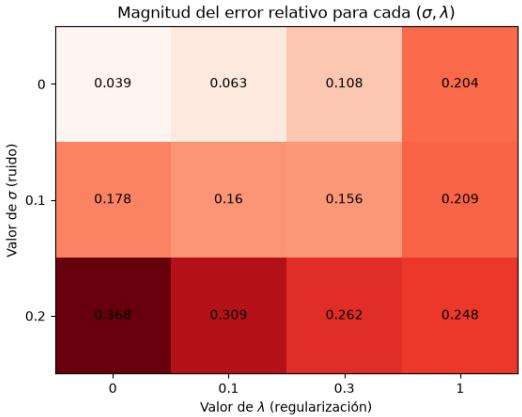
- Las tres imágenes son visualmente iguales; GD se detiene cerca del óptimo por el criterio de parada.
- En problemas grandes, armar y resolver con H es caro: ahí conviene GD.

Regularización cuadrática (Ej. 9)

$$J_{\sigma,\lambda}(x) = \tfrac{1}{2}\Big(\underbrace{\|A_7 x - b_\sigma\|^2}_{\text{fidelidad}} + \lambda \underbrace{\|Dx\|^2}_{\text{suavidad}} \Big), \qquad \nabla J = A_7^T(A_7 x - b_\sigma) + \lambda D^T D x$$

- $D = \begin{bmatrix} D_h \\ D_v \end{bmatrix} \in \mathbb{R}^{112\times 64}$: diferencias horizontales $X_{i,j+1} - X_{ij}$ y verticales $X_{i+1,j} - X_{ij}$.
- $D\, x_{\text{constante}} = 0 \quad$ vs. $\quad \|D x_{\text{fantoma}}\| \approx 2{,}71.$
- **Supuesto:** píxeles vecinos tienen valores parecidos (imagen suave).
- λ regula el compromiso:
  - λ chico $\to$ ajusta las mediciones, pero también el ruido.
  - λ grande $\to$ imagen suave, pero pierde bordes y contraste.
- Minimizamos con GD ($\alpha = 0{,}04$), cortando por variación del costo.

Ruido vs. regularización (Ej. 9)

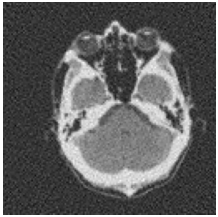


Mejor λ para cada nivel de ruido:

- $\sigma = 0$: $\lambda = 0$ (error 0,039)
- $\sigma = 0{,}1$: $\lambda = 0{,}3$ (error 0,156)
- $\sigma = 0{,}2$: $\lambda = 1$ (error 0,248)

- Sin ruido, regularizar **empeora**.
- A más ruido, más conviene regularizar.
- λ excesivo: imagen borrosa y de bajo contraste; D no distingue ruido de bordes reales.

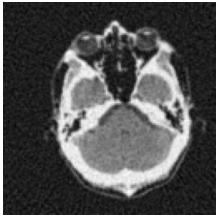
Elección de λ sin conocer la imagen (Ej. 10)



$\lambda = 0$

$\|r\| = 43{,}6$

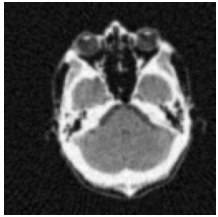
$\|D\hat{x}\| = 28{,}5$



$\lambda = 10$

$\|r\| = 55{,}4$

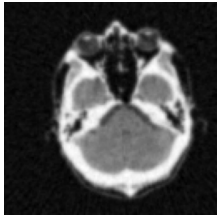
$\|D\hat{x}\| = 18{,}5$



$\lambda = 40$ (elegida)

$\|r\| = 77{,}8$

$\|D\hat{x}\| = 14{,}2$



$\lambda = 100$

$\|r\| = 102{,}6$

$\|D\hat{x}\| = 11{,}5$

- **Principio de discrepancia (Morozov):** no tiene sentido ajustar las mediciones mejor que el ruido, $\|A\hat{x}_\lambda - b\| \approx \|\eta\| \approx 76$.
- $\|r\| < \|\eta\| \Rightarrow$ se está ajustando el ruido (granulado). Elegimos $\lambda = 40$: el menor que supera el nivel de ruido, con bordes todavía nítidos.

Síntesis (Ej. 11)

Concepto	Qué nos permite analizar
Modelo $b = Ax$	La adquisición como transformación lineal; reconstruir es invertirla.
Rango y Nul(A)	Si las mediciones determinan una única imagen y qué queda invisible.
Mínimos cuadrados / proyección ortogonal	Qué hacer cuando el ruido saca a b de Col(A).
Autovalores de A^TA, GD y Newton	Cómo calcular la solución y con qué paso α converge.
Regularización $\lambda\|Dx\|^2$	Estabilizar frente al ruido: compromiso entre fidelidad y suavidad.

Un residuo chico no alcanza: hay que mirar unicidad, ruido y estructura de la imagen.